

面向SSE 50ETF期权市场的下一代生成式建模：基于物理信息的扩散模型技术深度研究报告

执行摘要

随着生成式人工智能(Generative AI)从单纯的图像与文本生成向复杂科学计算领域渗透，量化金融正在经历一场从传统的随机微分方程(SDE)向数据驱动的深度生成模型(Deep Generative Models, DGMs)的范式转移。针对您提出的利用扩散模型(Diffusion Models)生成符合真实市场特征的SSE 50ETF期权仿真数据的需求，本报告通过系统梳理2024年至2026年初的前沿文献，提出了一套**基于物理信息的潜在条件扩散模型(Physics-Informed Latent Conditional Diffusion Model, PI-LCDM)**解决方案。

SSE 50ETF期权作为中国金融衍生品市场的核心标的，其波动率曲面(Implied Volatility Surface, IVS)具有显著的非平稳性、反杠杆效应(Leverage Effect)以及独特的微观结构特征(如T+0交易、特定的行权价间隔规则等)。传统的生成对抗网络(GANs)和变分自编码器(VAEs)在处理此类高维、强约束的金融时间序列时，常面临模式崩塌(Mode Collapse)或生成分布过于平滑的问题，无法有效捕捉市场的尾部风险和极端波动。

本报告提出的SOTA(State-of-the-Art)方案融合了以下核心技术突破：

- 几何布朗运动(**GBM**)引导的前向过程：摒弃传统的加性高斯噪声，采用乘性噪声机制，使扩散过程内在地符合资产价格的对数正态分布特性和异方差性(Kim et al., 2025)。
- 潜在空间扩散(**Latent Diffusion**)：通过变分自编码器(VAE)将高维波动率曲面压缩至低维潜在流形，利用Transformer架构捕捉长程时序依赖(Tanaka et al., 2025)。
- 无套利物理约束(**PINA**)：在训练目标中引入信噪比(SNR)加权的无套利惩罚项，并在采样阶段使用梯度引导，强制生成的曲面满足蝶式价差和日历价差等经济学硬约束(Jin & Agarwal, 2025; Wong & Hui, 2026)。

本报告将分八个章节，共计约15,000字，详尽阐述该方案的理论基础、架构设计、工程实现及验证方法，旨在为专业量化团队提供一份可落地的实施蓝图。

1. 引言：金融衍生品生成式建模的演进与挑战

在量化金融领域，高质量的仿真数据是策略回测、风险管理及衍生品定价模型校准的基石。对于SSE 50ETF期权市场而言，由于历史数据相对有限(自2015年上市以来仅约十年数据)，且市场机制经历了多次微调，直接使用历史回放(Historical Replay)往往无法覆盖未来的极端市场情景。因此，构建一个能够生成“逼真且新颖”的市场数据的模拟器(Market Simulator)成为业界的迫切需求。

1.1 传统方法的局限性

在扩散模型兴起之前，市场模拟主要依赖两类方法：

- 参数化随机过程：如Heston模型、SABR模型或跳跃扩散模型(Jump-Diffusion)。这些模型虽然具有良好的解析性质和可解释性，但其参数形式过于刚性，难以捕捉真实市场中复杂的联合分布和非平稳的波动率动态¹。例如，传统的跳跃扩散模型虽然能解释厚尾分布，但在拟合SSE 50ETF的偏斜结构(Skew)随时间演变时往往表现欠佳。
- 早期生成式深度学习(GANs/VAEs)：
 - GANs：虽然在图像生成领域取得了巨大成功，但在金融时间序列中，GANs极易遭遇模式崩塌，即生成器只能产生有限几种常见的市场路径，而忽略了至关重要的黑天鹅事件³。此外，对抗训练的不稳定性常导致生成的波动率曲面出现违反无套利原则的“伪影”(Artifacts)，如负的隐含方差⁵。
 - VAEs：倾向于生成模糊的、平均化的样本。在期权市场中，这意味着生成的波动率曲面过于平滑，丢失了市场恐慌时微观结构导致的剧烈抖动和流动性断层特征⁶。

1.2 扩散模型的统治地位(2024-2026)

截至2026年初，扩散模型已无可争议地成为金融时间序列生成的SOTA技术。其核心优势在于：

1. 全分布覆盖：通过学习数据分布的得分函数(Score Function)，扩散模型能够覆盖数据整个支撑集，有效生成包含极端尾部风险的样本¹。
2. 训练稳定性：基于最大似然估计(MLE)或得分匹配(Score Matching)的训练目标是凸优化问题，避免了GANs的极小极大博弈陷阱⁸。
3. 可控性与条件生成：最新的架构(如CoFinDiff, DiffLOB)允许用户显式输入宏观条件(如“VIX指数上升50%”)，从而生成特定情景下的仿真数据，这对压力测试至关重要¹⁰。

1.3 针对SSE 50ETF的特殊考量

SSE 50ETF期权市场具有鲜明的中国特色：

- 微观结构：T+0交易制度、实物交割、严格的涨跌停板制度(期权涨跌幅由非线性公式决定，不同于股票的10%)¹¹。
- 波动率微笑：50ETF期权通常呈现显著的负偏斜(Smirk)，反映了市场对下行风险的极度厌恶。生成的仿真数据必须精确复现这一非对称性¹³。
- 数据稀疏性与网格化：期权合约随标的价格波动而加挂，导致行权价-到期日网格是动态变化的。如何将非结构化的日度交易数据转化为适合神经网络处理的张量，是工程落地的一大难点。

本报告将基于上述背景，详细拆解如何利用最新的扩散模型技术，构建一个既符合数学物理规律，又贴合SSE 50ETF市场特性的仿真系统。

2. 市场微观结构与数据预处理工程

在进入深度学习模型之前，必须对SSE 50ETF的原始日度数据进行严格的清洗、重构和标准化。数据的质量和表征形式直接决定了生成模型的上限。

2.1 SSE 50ETF期权合约特征分析

SSE 50ETF期权是上交所推出的首只ETF期权，其标的为华夏上证50ETF(代码510050)。在构建训练集时，必须考虑以下关键合约要素¹¹：

- 合约月份：当月、下月及随后两个季月（共4个到期月份）。这意味着在任意交易日，市场上同时存在4个期限的期权链。
- 行权价网格：行权价间距并非固定，而是根据行权价所处区间分段设定（如3元以下间距0.05元，3-5元间距0.1元等）。这种非均匀网格在输入神经网络前必须进行标准化处理。
- 熔断与涨跌停：期权价格有严格的日内波动限制。例如，看涨期权涨停价 = 前结算价 + $\text{Max}(0.5 \times \text{标的前收盘价}, \text{标的前收盘价} \times 10\%)$ 。仿真数据若突破此边界，即为无效数据。

2.2 数据清洗与增强策略

基于2025年的最佳实践¹⁵，数据预处理应包含以下步骤：

2.2.1 静态无套利筛查

在训练前，必须剔除原始数据中明显的套利机会，以免模型学习到错误的市场定价逻辑。

- 单调性检查：对于看涨期权，价格应随行权价 K 单调递减；看跌期权则递增。
- 凸性检查（蝴蝶价差）：价格曲线必须是下凸的（Convex）。即
$$C(K_{i-1}) - 2C(K_i) + C(K_{i+1}) \geq 0。$$
- 边界条件： $S_t - Ke^{-rT} \leq C_t \leq S_t$ 。对于SSE 50ETF，需使用SHIBOR作为无风险利率 r 的代理¹⁷。

2.2.2 流动性过滤与主力合约选择

50ETF期权的流动性高度集中在近月平值(ATM)附近。远月深实值或深虚值合约往往买卖价差巨大甚至无成交。

- 规则：仅保留交易量大于阈值（如100张）或持仓量大于阈值的合约。对于缺失数据，不应简单填充0，而应标记为缺失或使用插值填补。
- 展期处理：构建连续的时间序列时，需在当月合约到期前（通常是第四个星期三）进行主力合约切换，通常选择持仓量最大的月份作为主力¹⁷。

2.3 隐含波动率曲面(IVS)的构建与张量化

直接对期权价格建模存在标的价格非平稳性的问题。SOTA方案是对隐含波动率曲面或局部波动率曲面进行建模，因为它们更平稳且直接反映市场情绪⁸。

2.3.1 网格标准化(Grid Standardization)

神经网络(如CNN或Transformer)通常需要固定维度的输入。我们需要将非结构化的期权链数据映射到固定的 (m, τ) 网络上:

- **Moneyness (m):** 定义对数虚值程度(Log-moneyness) $k = \log(K/F_T)$, 其中 $F_T = S_t e^{(r-q)T}$ 。设定固定网格, 例如 $k \in \{-0.2, -0.15, \dots, 0.2\}$ 。
- **Tenor (τ):** 设定固定期限, 例如 $\tau \in \{30, 60, 90, 180\}$ 天。

2.3.2 SVI参数化插值

为了从稀疏的市场数据中获得密集的网格数据, 推荐使用**SVI(Stochastic Volatility Inspired)**模型进行插值¹³。SVI模型能够保证极限条件下的无套利性, 且能很好地拟合50ETF的波动率微笑。具体步骤如下:

1. 对每个交易日、每个到期期限, 拟合原始SVI参数 (a, b, ρ, m, σ) 。
2. 利用拟合好的参数, 计算固定网格点上的隐含波动率。
3. 最终生成的数据形式为每日一个张量 $\mathbf{X}_t \in \mathbb{R}^{C \times H \times W}$, 其中 H 为期限数量, W 为行权价数量, C 为通道数(可包含隐含波动率、历史波动率、交易量等特征图)。

3. 理论框架: 分数基生成扩散模型 (Score-Based Generative Models)

本方案的核心算法基于分数基生成模型(SBGM), 这是扩散模型在连续时间上的推广形式, 特别适合处理金融时间序列。

3.1 前向过程: 几何布朗运动引导的SDE

传统的扩散模型(如DDPM)使用加性高斯噪声破坏数据, 这在图像领域效果良好, 但对于金融数据, 这种各向同性的噪声忽略了资产价格的异方差性(Heteroskedasticity)。Kim et al. (2025)提出的**GBM引导扩散(GBM-guided Diffusion)**是目前SOTA方法¹。

该方法将前向过程定义为:

$$d\mathbf{x}_t = \mathbf{f}(\mathbf{x}_t, t)dt + g(t) \cdot \mathbf{x}_t \cdot d\mathbf{w}_t$$

注意扩散项 $g(t) \cdot \mathbf{x}_t$, 噪声的大小与当前状态值成正比。这在对数空间中等价于:

$$d(\log \mathbf{x}_t) = (\dots)dt + g(t)d\mathbf{w}_t$$

物理意义:这种设计使得模型在生成过程中,对于高波动率状态会自然地注入更大的随机性,而在低波动率状态注入较小随机性,完美契合金融市场的乘性波动特征。这解决了传统GAN生成的数据缺乏“波动率聚类”现象的痛点²⁰。

3.2 反向过程与分数匹配

生成过程通过求解反向SDE实现:

$$d\mathbf{x}_t = [\mathbf{f}(\mathbf{x}_t, t) - g(t)^2 \nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t)]dt + g(t)d\bar{\mathbf{w}}_t$$

这里的关键是学习分数函数(Score Function) $\nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t)$ 。我们使用一个时间相关的神经网络 $s_{\theta}(\mathbf{x}_t, t)$ 来逼近它。

训练目标采用去噪分数匹配(Denoising Score Matching):

$$\mathcal{L}(\theta) = \mathbb{E}_{t, \mathbf{x}_0, \mathbf{x}_t} [\lambda(t) \|s_{\theta}(\mathbf{x}_t, t) - \nabla_{\mathbf{x}_t} \log p_{0t}(\mathbf{x}_t | \mathbf{x}_0)\|_2^2]$$

其中 p_{0t} 是前向过程的转移核,对于GBM过程,它是一个对数正态分布,这是可以解析求解的⁸。

4. SOTA架构设计:潜在条件扩散与物理校正

针对SSE 50ETF期权项目,我们建议采用一种混合架构,结合潜在空间建模、条件控制和**物理信息神经网络(PINN)**的思想。

4.1 整体架构:CoFinDiff与Latent Diffusion的融合

鉴于波动率曲面数据的高维冗余性(相邻行权价和期限的IV高度相关),直接在高维像素空间进行扩散效率低下且难以训练。推荐采用**潜在扩散(Latent Diffusion)**架构²²:

1. 变分自编码器(VAE)压缩:

- 首先训练一个VAE,将 32×32 的IVS张量压缩为 4×4 的潜在向量 $\mathbf{z}$ 。
- VAE的重构损失函数中应加入**感知损失(Perceptual Loss)**或针对梯度的惩罚,以确保重构出的曲面保持平滑且保留局部特征(如ATM附近的斜率)。

2. 条件去噪网络(Conditional Denoiser):

- 在潜在空间 $\mathbf{z}$ 上进行扩散过程。
- 主干网络推荐使用 **DiT (Diffusion Transformer)** 或 **U-Net**,其中Transformer在捕捉时间序列的长程依赖上表现更优¹。
- 条件注入机制:参考 **CoFinDiff** (Tanaka et al., 2025) 的设计,通过**交叉注意力机制(Cross-Attention)**将市场状态(Condition)注入到生成过程中¹⁰。

4.2 条件向量的设计

为了生成“符合真实市场”的数据，必须告诉模型当前的市场环境。条件向量 $\mathbf{c}$ 应包含：

- 标的资产特征：50ETF过去N日的收益率序列、MACD指标。
- 宏观波动率指标：中国波指(iVIX)的历史水平²⁴。
- 微观结构特征：历史买卖价差(Bid-Ask Spread)的平均水平，反映流动性状态。

通过这种设计，您可以实现可控生成：例如，设定 $\mathbf{c}$ 为2015年股灾期间的指标，模型即可生成该极端环境下的波动率曲面演化路径。

4.3 物理信息无套利校正器(PINA Corrector)

这是本方案中最具创新性和专业性的部分。为了保证生成的IVS不包含静态套利机会，我们在反向采样过程中引入**物理信息无套利(Physics-Informed No-Arbitrage, PINA)**校正器²⁵。

在每一步去噪 $\mathbf{z}_t \rightarrow \mathbf{z}_{t-1}$ 后，增加一个梯度下降步骤：

$$\mathbf{z}_{t-1}^{\text{corrected}} = \mathbf{z}_{t-1} - \eta \nabla_{\mathbf{z}} \mathcal{L}_{\text{arb}}(\mathcal{D}(\mathbf{z}_{t-1}))$$

其中 $\mathcal{D}$ 是VAE的解码器， $\mathcal{L}_{\text{arb}}$ 是定义的套利惩罚函数(详见第5章)。这相当于在生成过程中，实时地将数据“推”回到无套利流形上。

5. 金融现实主义的数学保障：损失函数与约束

为了通过图灵测试(即让资深交易员无法区分真假数据)，模型必须严格遵守金融定律。

5.1 SNR加权的无套利损失函数

Jin & Agarwal (2025) 提出了一种动态加权的损失函数设计²⁶。在训练阶段，总损失函数为：

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{DSM}} + \gamma(t) \cdot \mathcal{L}_{\text{arb}}$$

其中 $\gamma(t)$ 是基于信噪比(SNR)的动态权重。

- 在扩散早期(高噪声, $t \rightarrow T$), $\gamma(t)$ 较小, 模型主要学习数据的全局分布结构。
- 在扩散晚期(低噪声, $t \rightarrow 0$), $\gamma(t)$ 增大, 强制模型在精细化生成阶段严格遵守无套利约束。

5.2 具体的套利约束公式

针对SSE 50ETF期权, 我们需要具体化以下惩罚项 $\mathcal{L}_{\text{arb}}$ ⁸:

1. 日历价差约束(**Calendar Spread**):

同执行价的期权, 期限越长价格应越高(不考虑红利极大情况)。

$$\mathcal{L}_{\text{cal}} = \sum_{i,j} \text{ReLU}(C(K_i, T_j) - C(K_i, T_{j+1}))$$

其中 $T_{j+1} > T_j$ 。

2. 蝶式价差约束(**Butterfly Spread**):

期权价格关于执行价 K 必须是凸函数(Convex), 这保证了风险中性概率密度非负。

$$\mathcal{L}_{\text{fly}} = \sum_{i,j} \text{ReLU}(2C(K_i, T_j) - C(K_{i-1}, T_j) - C(K_{i+1}, T_j))$$

注意: 这里假设行权价网格是等间距的。如果是不等间距(SSE 50ETF实际情况), 需调整为二阶差分形式。

3. 垂直价差约束(**Vertical Spread**):

看涨期权价格随 K 单调递减。

$$\mathcal{L}_{\text{vert}} = \sum_{i,j} \text{ReLU}(C(K_{i+1}, T_j) - C(K_i, T_j))$$

这些约束是在隐含波动率曲面解码回价格曲面后计算的, 利用自动微分框架(如PyTorch Autograd)可以轻松实现反向传播。

6. 项目实施路线图与工程细节

基于上述理论, 以下是针对您项目的具体实施步骤。

阶段一: 数据工程(预计耗时: 2-3周)

1. 数据清洗:

- 载入日度50ETF期权数据。
- 剔除成交量<50张的合约。
- 剔除满足 $P < S - Ke^{-rT}$ 的明显套利样本。

2. 曲面拟合:

- 对于每一天, 使用Quasi-Explicit SVI校准算法拟合原始数据。

- 在标准化网格 ($m \in [-0.3, 0.3], \tau \in [0.1, 1.0]$) 上采样, 生成 32×32 的IVS图像。
3. 特征工程:
- 计算50ETF的历史波动率(RV)、iVIX、以及期限结构斜率(Term Structure Slope)作为条件向量 $\mathbf{c}$ 。

阶段二: 模型训练(预计耗时: 3-4周)

1. VAE预训练:
- 仅使用IVS图像训练VAE, 确保重构损失(MSE)降至 10^{-4} 级别, 保证潜在空间包含了曲面的主要特征。
2. 扩散模型训练:
- 构建条件Transformer架构。
 - 使用GBM噪声调度(Noise Schedule)。
 - 引入SNR加权的 $\mathcal{L}_{\text{arb}}$ 进行端到端训练。
 - 主要超参数: 扩散步数 $T = 1000$, Batch Size=64, Learning Rate= $2e-4$ 。

阶段三: 采样与应用(持续迭代)

- 生成数据: 给定特定的市场条件 $\mathbf{c}$, 生成大量合成IVS。
- PINA校正: 在最后50步去噪过程中, 开启梯度校正, 微调生成的曲面。
- 还原价格: 结合模拟的标的价格(可使用简单的GBM或Heston模拟), 通过Black-Scholes公式将合成IVS转化为期权价格。

7. 评估体系与Deep Hedging验证

如何证明生成的仿真数据是“专业”且“有用”的? 我们建议从以下三个维度建立评估体系²⁸。

7.1 统计保真度(Statistical Fidelity)

- 分布距离: 计算真实数据与合成数据在关键指标(如ATM波动率、偏度skew、峰度kurtosis)上的Wasserstein距离和KL散度。
- 自相关性(ACF): 检查合成波动率序列是否复现了真实市场的“长记忆性”(Long Memory)和波动率聚类特征。
- 杠杆效应复现: 验证合成数据中, 标的收益率与波动率变化的相关系数是否为负(SSE 50ETF通常在 -0.4 到 -0.6 之间)。

7.2 金融一致性(Financial Consistency)

- 希腊字母合理性(Greeks Reasonableness): 从合成曲面计算Delta、Gamma和Vega。检查

Gamma曲面是否平滑, 是否存在异常的负值区域³¹。

- 无套利通过率: 统计所有生成的曲面中, 违反静态套利约束的样本比例。SOTA模型应控制在0.1%以下。

7.3 下游任务验证: Deep Hedging Backtest

这是检验数据有效性的“金标准”³²。

1. 实验设计: 训练一个深度强化学习(DRL)对冲智能体。
2. 训练集: 仅使用扩散模型生成的仿真数据进行训练。
3. 测试集: 在真实的历史50ETF数据上进行回测。
4. 评价指标: 比较该智能体与在真实数据上训练的智能体的对冲误差(Hedging Error)和夏普比率。
 - 结论: 如果两者性能接近(Performance Gap < 5%), 说明仿真数据成功捕捉了市场的核心动力学特征, 即所谓的“Train on Synthetic, Test on Real”(TSTR) 成功。

8. 结论与建议

针对您的项目, 最专业且SOTA的方案是构建一个基于物理信息的潜在条件扩散模型(PI-LCDM)。

核心建议总结:

1. 放弃GANs, 拥抱扩散模型, 以解决模式崩塌和训练不稳定性问题。
2. 不要只做图像生成, 必须结合GBM前向过程和无套利损失函数, 这是金融领域应用的特殊要求。
3. 重视数据预处理, 利用SVI插值构建标准化的训练集是模型成功的关键前提。
4. 以Deep Hedging为最终验证, 这不仅能证明数据的质量, 还能直接体现该项目在量化交易中的商业价值。

此方案代表了2025-2026年量化金融文献中的最高水平, 结合了深度学习的表达能力与金融数学的严谨性, 能够生成既逼真又可用的SSE 50ETF期权仿真数据。

部分参考文献索引:

- ¹
Kim et al. (2025). "A diffusion-based generative model for financial time series via geometric Brownian motion." *arXiv:2507.19003*.
- ²⁶
Jin & Agarwal (2025). "Forecasting implied volatility surface with generative diffusion models." *arXiv:2511.07571*.
- ¹⁰
Tanaka et al. (2025). "CoFinDiff: Controllable Financial Diffusion Model." *IJCAI 2025*.

- 25

Wong & Hui. "Arbitrage-free implied volatility surface completion." *University of Waterloo Research*.

- 35

Berti et al. (2025). "TRADES: Generating Realistic Market Simulations." *arXiv:2502.07071*.

9. 附录：关键算法实现细节与伪代码

为了进一步辅助您的项目落地，本章节提供核心模块的算法逻辑描述。

9.1 SVI校准算法（数据预处理）

SVI参数化形式为：

$$\sigma_{\text{SVI}}^2(k) = a + b \left(\rho(k - m) + \sqrt{(k - m)^2 + \sigma^2} \right)$$

针对50ETF数据的每日校准流程：

- 输入：当日各行权价 K_i 对应的市场隐含波动率 $\sigma_{\text{mkt}}(K_i)$ 。
- 优化目标：最小化加权均方误差 $\sum_i w_i (\sigma_{\text{SVI}}(k_i) - \sigma_{\text{mkt}}(K_i))^2$ 。权重 w_i 可取为Vega值，以重视ATM期权。
- 约束：确保 $b \geq 0, |\rho| < 1, \sigma > 0, a + b\sigma\sqrt{1 - \rho^2} \geq 0$ 以保证无静态套利。
- 输出：固定网格上的IVS图像。

9.2 信噪比加权损失函数（训练阶段）

基于Jin & Agarwal (2025) 的实现逻辑：

Python

```
def loss_function(model, x_0, condition, t):  
    # 1. 前向加噪 (GBM-guided)  
    noise = torch.randn_like(x_0)  
    # alpha_t, sigma_t 根据GBM调度计算  
    x_t = x_0 * alpha_t + x_0 * sigma_t * noise  
  
    # 2. 模型预测噪声  
    predicted_noise = model(x_t, t, condition)  
    mse_loss = F.mse_loss(predicted_noise, noise)
```

```

# 3. 恢复预测的x_0 (Denoised estimate)
x_0_hat = (x_t - x_t * sigma_t * predicted_noise) / alpha_t

# 4. 计算无套利惩罚 (在x_0_hat上计算)
arb_loss = calculate_arbitrage_violation(x_0_hat)

# 5. 动态权重 lambda(t) = SNR(t) / (SNR(t) + 1)
snr = (alpha_t / sigma_t) ** 2
lambda_t = snr / (snr + 1.0)

return mse_loss + lambda_t * arb_loss

```

9.3 物理信息采样校正（推理阶段）

在生成循环中嵌入PINA校正：

Python

```

def p_sample_loop_with_correction(model, shape, condition):
    z = torch.randn(shape) # 初始潜在向量
    for t in reversed(range(0, T)):
        # 1. 标准反向扩散步
        z = diffusion_step(model, z, t, condition)

        # 2. 物理校正步 (PINA)
        z.requires_grad = True
        ivs_approx = decoder(z) # 解码为IVS
        loss_arb = calculate_arbitrage_violation(ivs_approx)

        grad = torch.autograd.grad(loss_arb, z)
        z = z - learning_rate_correction * grad # 梯度下降修正
        z = z.detach()

    return decoder(z)

```

通过上述详尽的技术路径与实施细节，您可以构建出一个处于学术界与工业界最前沿的SSE 50ETF期权市场仿真器。

引用的著作

1. [2507.19003] A diffusion-based generative model for financial time series via geometric Brownian motion - arXiv, 访问时间为 二月 15, 2026, <https://arxiv.org/abs/2507.19003>
2. A Jump-Diffusion Model for Option Pricing | Management Science - PubsOnLine, 访问时间为 二月 15, 2026, <https://pubsonline.informs.org/doi/10.1287/mnsc.48.8.1086.166>
3. [2410.18897] Generation of synthetic financial time series by diffusion models - arXiv, 访问时间为 二月 15, 2026, <https://arxiv.org/abs/2410.18897>
4. GANs vs. Diffusion Models: In-Depth Comparison and Analysis - Sapien, 访问时间为 二月 15, 2026, <https://www.sapien.io/blog/gans-vs-diffusion-models-a-comparative-analysis>
5. GAN-Enhanced Implied Volatility Surface Reconstruction for Option Pricing Error Mitigation - IEEE Xplore, 访问时间为 二月 15, 2026, <https://ieeexplore.ieee.org/iel8/6287639/10820123/11197507.pdf>
6. Generative Models Explained: VAEs, GANs, Diffusion, Transformers, Autoregressive Models & NeRFs - Bestarion USA, 访问时间为 二月 15, 2026, <https://bestarion.com/us/generative-models-explained-vaes-gans-diffusion-transformers-autoregressive-models-nerfs/>
7. Score-Based Diffusion Models - Emergent Mind, 访问时间为 二月 15, 2026, <https://www.emergentmind.com/topics/score-based-diffusion-model>
8. Forecasting implied volatility surface with generative diffusion models¹ footnote 1 Full code available on https://github.com/Austinjinc/rep_volgan/tree/refactor/new-ddpm - arXiv, 访问时间为 二月 15, 2026, <https://arxiv.org/html/2511.07571v1>
9. GANs vs Diffusion Generative AI Comparison | SabrePC Blog, 访问时间为 二月 15, 2026, <https://www.sabrepc.com/blog/Deep-Learning-and-AI/gans-vs-diffusion-models>
10. [2503.04164] CoFinDiff: Controllable Financial Diffusion Model for Time Series Generation - arXiv, 访问时间为 二月 15, 2026, <https://arxiv.org/abs/2503.04164>
11. SSE 50 Index Options | CFFEX, 访问时间为 二月 15, 2026, http://www.cffex.com.cn/en_new/SSE50IndexOptions.html
12. SSE 50ETF Options Contract Specification - SHANGHAI STOCK EXCHANGE, 访问时间为 二月 15, 2026, <https://english.sse.com.cn/markets/derivatives/overview/50etf/>
13. Prediction of the implied volatility surface—An empirical analysis of the SSE 50ETF option based on CNNs - IDEAS/RePEc, 访问时间为 二月 15, 2026, <https://ideas.repec.org/a/eee/finlet/v77y2025ics1544612325003824.html>
14. Price discovery among SSE 50 Index-based spot, futures, and options markets, 访问时间为 二月 15, 2026, https://www.researchgate.net/publication/328658543_Price_discovery_among_SSE_50_Index-based_spot_futures_and_options_markets
15. How to Clean Data for Machine Learning Best Practices and Tools | Udacity, 访问时间为 二月 15, 2026,

- <https://www.udacity.com/blog/2025/01/how-to-clean-data-for-machine-learning-best-practices-and-tools.html>
16. Data Cleaning in Machine Learning: Best Practices and Methods - eInfochips, 访问时间为 二月 15, 2026, <https://www.einfochips.com/blog/data-cleaning-in-machine-learning-best-practices-and-methods/>
 17. Pricing of Shanghai stock exchange 50 ETF options based on different volatility models, 访问时间为 二月 15, 2026, <https://pmc.ncbi.nlm.nih.gov/articles/PMC10703202/>
 18. Volatility surface completion using score-based generative models - University of Waterloo, 访问时间为 二月 15, 2026, https://uwaterloo.ca/computational-mathematics/sites/default/files/uploads/documents/ying_kit_hui_research_paper.pdf
 19. Higher-order spline outperforms Wall Street model in forecasting China's implied volatility, 访问时间为 二月 15, 2026, <https://e3.eurekalert.org/news-releases/1104482>
 20. A diffusion-based generative model for financial time series via geometric Brownian motion, 访问时间为 二月 15, 2026, <https://arxiv.org/html/2507.19003v1>
 21. A diffusion-based generative model for financial time series via geometric Brownian motion - arXiv, 访问时间为 二月 15, 2026, <https://arxiv.org/pdf/2507.19003>
 22. Latent Space Diffusion for Topology Optimization - arXiv, 访问时间为 二月 15, 2026, <https://arxiv.org/html/2508.05624v1>
 23. Exploring Diffusion Models for Generative Forecasting of Financial Charts - arXiv, 访问时间为 二月 15, 2026, <https://arxiv.org/html/2509.02308v1>
 24. Research on Pricing of Shanghai 50ETF Options Based on Fractal B-S Model and GARCH Model - Scientific Research Publishing, 访问时间为 二月 15, 2026, <https://www.scirp.org/journal/paperinformation?paperid=98354>
 25. Completion of Option Price Surfaces Using Score-based Generative Models with Guided Diffusion - University of Waterloo, 访问时间为 二月 15, 2026, https://uwaterloo.ca/computational-mathematics/sites/default/files/uploads/documents/research-paper_po-chai-wong.pdf
 26. [2511.07571] Forecasting implied volatility surface with generative diffusion models - arXiv, 访问时间为 二月 15, 2026, <https://arxiv.org/abs/2511.07571>
 27. 访问时间为 一月 1, 1970, https://github.com/Austinjinc/rep_volgan/tree/refactor/new-ddpm
 28. A Comprehensive Evaluation Framework for Synthetic Time Series Data - Diva-portal.org, 访问时间为 二月 15, 2026, <http://www.diva-portal.org/smash/get/diva2:1954330/FULLTEXT01.pdf>
 29. [PDF] An evaluation framework for synthetic data generation models - Semantic Scholar, 访问时间为 二月 15, 2026, <https://www.semanticscholar.org/paper/An-evaluation-framework-for-synthetic-data-models-Livieris-Alimpertis/c62edfb5ab4c8cab78148b0714958e711eae0314>
 30. Evaluating generative models for synthetic financial data - arXiv, 访问时间为 二月 15, 2026, <https://arxiv.org/html/2512.21791v1>

31. Barrier Options and Greeks: Modeling with Neural Networks - ResearchGate, 访问时间为 二月 15, 2026, https://www.researchgate.net/publication/370093011_Barrier_Options_and_Greeks_Modeling_with_Neural_Networks
32. Governing synthetic data in the financial sector | Finance and Society | Cambridge Core, 访问时间为 二月 15, 2026, <https://www.cambridge.org/core/journals/finance-and-society/article/governing-synthetic-data-in-the-financial-sector/BFBAEAD4A6E8EE8D0C0BD328CC056274>
33. Deep Hedging with Options Using the Implied Volatility Surface François is supported by a fellowship from the Canadian Institute of Derivatives. Gauthier is supported by the Natural Sciences and Engineering Research Council of Canada (NSERC, RGPIN-2024-03791), a professorship funded by HEC Montréal, and the HEC Montréal Foundation. Godin is funded by NSERC (- arXiv, 访问时间为 二月 15, 2026, <https://arxiv.org/html/2504.06208v3>
34. Full article: Empirical deep hedging - Taylor & Francis, 访问时间为 二月 15, 2026, <https://www.tandfonline.com/doi/full/10.1080/14697688.2022.2136037>
35. [2502.07071] TRADES: Generating Realistic Market Simulations with Diffusion Models, 访问时间为 二月 15, 2026, <https://arxiv.org/abs/2502.07071>